

Tech Challenge – Fase 1

Alessandro Dos Santos - RM376092

André Palermo - RM374038

Michel Lages Balbuena - RM375667

Spencer Bento - RM377023

Willian Souza - RM375240

Relatório Executivo de Engenharia de Dados e Proposta de IA Agêntica

Tech Challenge — Fase 1 (Caso: Plataforma Olist)

 **Vídeo Executivo (Link):** [Cole aqui o link do vídeo gravado]

1. Visão Geral do Negócio (Olist)

A **Olist** é um ecossistema integrador de marketplaces operando como PaaS (Platform as a Service) no e-commerce brasileiro. A plataforma viabiliza que pequenos e médios varejistas (PMEs) publiquem e vendam seus produtos em grandes canais de vendas do país sob uma marca única unificada, centralizando a gestão de catálogos, processamento de pedidos, faturamento e logística.

Tech Challenge – Fase 1

Alessandro Dos Santos - RM376092

André Palermo - RM374038

Michel Lages Balbuena - RM375667

Spencer Bento - RM377023

Willian Souza - RM375240

Fluxo Transacional do E-commerce:




Diagrama 1

Tech Challenge – Fase 1

Alessandro Dos Santos - RM376092

André Palermo - RM374038

Michel Lages Balbuena - RM375667

Spencer Bento - RM377023

Willian Souza - RM375240

2. Diagnóstico da Qualidade de Dados (Data Discovery)

O ecossistema de dados da Olist é constituído por 9 tabelas relacionais de dados reais (coletados de Set/2016 a Out/2018). Executamos análises completas para identificar anomalias e falhas de consistência estrutural.

2.1 Inventário dos Dados

- `olist_orders_dataset.csv` (99.441 linhas): Cadastro mestre de pedidos.
- `olist_order_items_dataset.csv` (112.650 linhas): Detalhamento de itens por pedido (1:N).
- `olist_order_payments_dataset.csv` (103.886 linhas): Formas de pagamento utilizadas (1:N).
- `olist_order_reviews_dataset.csv` (99.224 linhas): Pesquisas de satisfação e comentários de clientes (1:N).
- `olist_customers_dataset.csv` (99.441 linhas): Cadastro demográfico de clientes.
- `olist_products_dataset.csv` (32.951 linhas): Catálogo de produtos cadastrados.
- `olist_sellers_dataset.csv` (3.095 linhas): Vendedores cadastrados na rede.
- `olist_geolocation_dataset.csv` (1.000.163 linhas): Coordenadas de latitude/longitude por CEP.
- `product_category_name_translation.csv` (71 linhas): Tradução de categorias PT-BR para EN.

2.2 Problemas de Qualidade Identificados

- **Produtos sem Categoria (610 produtos):** 1,85% do catálogo de produtos não possuía classificação, embora contivesse peso e dimensões físicas. Essa lacuna afetou **1.603 itens vendidos** (1,32% da receita total).
 - **Reviews com IDs Duplicados (814 duplicatas):** Detectamos 789 IDs de reviews repetidos. O diagnóstico indicou que os registros continham dados de texto e score idênticos, porém com `order_id` distintos. O comportamento reflete avaliações automáticas ou a replicação do mesmo feedback para múltiplos pedidos feitos simultaneamente pelo mesmo cliente.
 - **Armadilha do ID de Cliente:** `customer_id` é transacional (muda a cada novo pedido), enquanto o cliente real e recorrente deve ser identificado pelo `customer_unique_id`. O uso incorreto mascara a real retenção.
 - **Ineficiência de Geolocalização:** O dataset de geolocalização possui 1 milhão de coordenadas brutas, contendo centenas de pontos de latitude/longitude diferentes para o mesmo CEP.
-

Tech Challenge – Fase 1

Alessandro Dos Santos - RM376092

André Palermo - RM374038

Michel Lages Balbuena - RM375667

Spencer Bento - RM377023

Willian Souza - RM375240

3. Decisões de Tratamento e Unificação

Para gerar uma base analítica coesa, implementamos um script baseado nas diretrizes das decisões descritas a seguir:

1. **Granularidade nível Pedido (99.441 linhas):** Agregamos itens de compra (order_items) por order_id somando valores financeiros (price_total, freight_total) e contando a quantidade de itens.
 2. **Integração de Geolocalização:** Agregamos as coordenadas geográficas de latitude/longitude pela **mediana** agrupada por CEP. Anexamos as coordenadas finais para clientes (customer_lat, customer_lng) e vendedores (seller_lat, seller_lng).
 3. **Tratamento de Nulos:** Rotulamos os produtos sem categoria como "sem_categoria" (e "uncategorized" na coluna em inglês).
 4. **Deduplicação de Reviews:** Deduplicamos as avaliações com base no order_id (mantendo o primeiro registro) antes do join.
 5. **Formato de Saída:** Exportado para **olist_unified.csv** (65.7 MB, 52 colunas). A documentação detalhada do schema está disponível em **olist_unified_schema.md**.
-

Tech Challenge – Fase 1

Alessandro Dos Santos - RM376092

André Palermo - RM374038

Michel Lages Balbuena - RM375667

Spencer Bento - RM377023

Willian Souza - RM375240

4. Análise de Correlação: Tempo de Entrega vs. Satisfação

Executada via **analise_correlacao.py** sobre 95.824 pedidos entregues que continham avaliações válidas.

4.1 Resultados de Correlação

- **Correlação de Spearman (Review Score vs. delay_days):** -0.1758 (Correlação negativa relevante).
- **Correlação de Spearman (Review Score vs. lead_time_days):** -0.2346 .

4.2 Métricas Detalhadas por Nota:

- **Nota ★ 1 (Detratores):** Apresentou uma taxa de atraso alarmante de **37.9%**, sofrendo atrasos logísticos médios de **3,3 dias** além do prazo prometido.
- **Nota ★ 5 (Promotores):** Apresentou apenas **3.0%** de taxa de atraso, sendo entregues em média **12,7 dias antes** do prazo limite.

4.3 O Impacto no NPS:

A separação categórica da base revela o impacto devastador do atraso logístico sobre os indicadores de retenção:

Categoria	Pedidos	Nota Média (1 a 5)	NPS Proxy	Classificação de Qualidade
No Prazo	88.163	4.29	+73.6	Zona de Qualidade/Excelência
Atrasado	7.661	2.57	-19.5	Zona Crítica (Detração Pura)

Quando ocorre atraso, o NPS Proxy cai **93.1 pontos**, derrubando a nota média de 4.29 para 2.57.

Tech Challenge – Fase 1

Alessandro Dos Santos - RM376092

André Palermo - RM374038

Michel Lages Balbuena - RM375667

Spencer Bento - RM377023

Willian Souza - RM375240

5. Análise de Segmentação RFM

Análise executada sobre a base de **96.096 clientes únicos**.

Devido à baixíssima recompra estrutural da Olist no período (96.8% dos clientes realizaram apenas uma compra no histórico), a pontuação de Frequência (F) foi dividida em faixas customizadas (1 para F=1, 3 para F=2 e 5 para F>=3), e Recência (R) e Monetário (M) divididos em quintis.

5.1 Distribuição dos Segmentos de Clientes:

Segmento	Clientes	% Clientes	Recência Média	Freq. Média	Monetário Médio	Receita Total	% Receita
Novos Promissores	22.451	23.4%	141.8 dias	1.00	R\$ 207.92	R\$ 4.667.943.76	34.3%
Hibernando	21.585	22.5%	445.8 dias	1.00	R\$ 212.12	R\$ 4.578.613.63	33.7%
Prestes a Dormir	18.414	19.2%	271.2 dias	1.00	R\$ 129.27	R\$ 2.380.299.11	17.5%
Perdidos	15.791	16.4%	447.5 dias	1.00	R\$ 38.59	R\$ 609.309.44	4.5%
Novos Clientes	14.858	15.5%	139.5 dias	1.00	R\$ 38.81	R\$ 576.655.79	4.2%
Fiéis	1.624	1.7%	184.4 dias	2.04	R\$ 271.71	R\$ 441.249.23	3.2%
Em Risco de Churn	1.054	1.1%	433.4 dias	2.08	R\$ 251.09	R\$ 264.648.51	1.9%
Campeões	130	0.1%	142.6 dias	3.52	R\$ 489.53	R\$ 63.638.71	0.5%

5.2 Insights Relevantes

- **Oportunidade nos Hibernantes:** O grupo representa 22.5% da base de clientes e é responsável por **33.7% do faturamento total**. Com ticket médio robusto de R\$ 212,12 mas sem compras recentes (média 445 dias), reativá-los via IA com sugestões customizadas trará alto retorno financeiro.
- **Novos Promissores:** É o maior cluster financeiro (34.3% do faturamento). Devem ser impactados proativamente para que gerem a segunda compra e transitem para o grupo de Fiéis.

Tech Challenge – Fase 1

Alessandro Dos Santos - RM376092

André Palermo - RM374038

Michel Lages Balbuena - RM375667

Spencer Bento - RM377023

Willian Souza - RM375240

6. Mapa de Agentes de IA (Entregável 2 — PDF Tech Challenge)

Conforme os requisitos da Fase 1, propomos a implementação de **3 agentes inteligentes de IA** integrados para atuar sobre as principais dores operacionais e financeiras identificadas nas análises de dados da Olist (atraso logístico de 8,1%, taxa de recompra de apenas 3,12% e 11,5% de reviews detratores).

6.1 Agente 1: Review Intelligence Agent (Agente de Satisfação)

- **Nome do Agente:** Review Intelligence Agent (Agente de CX & NPS)
 - **Objetivo:** Analisar avaliações de clientes em tempo real, classificar automaticamente a causa raiz da insatisfação, identificar produtos defeituosos e gerar rascunhos de respostas personalizadas ao consumidor.
 - **Problema Resolvido:** Alto volume de comentários em formato livre (41,3% dos reviews contêm texto) sem categorização sistemática, gerando demora no atendimento e perda de NPS.
 - **Usuários Envolvidos:** Equipe de Customer Experience (CX) da Olist, Analistas de Atendimento e Vendedores (Sellers).
 - **Ancoragem Analítica nos Dados:** O dataset `olist_order_reviews_dataset` possui 99.224 registros com 11,51% de avaliações Nota 1. A análise de correlação provou que clientes no prazo possuem NPS de +73.6, enquanto clientes com atraso caem para -19.5 (Zona Crítica).
 - **Benefício Esperado:** Resposta instantânea a detratores, recuperação proativa de clientes insatisfeitos e bloqueio preventivo de anúncios com problemas recorrentes de qualidade.
-

Tech Challenge – Fase 1

Alessandro Dos Santos - RM376092

André Palermo - RM374038

Michel Lages Balbuena - RM375667

Spencer Bento - RM377023

Willian Souza - RM375240

6.2 Agente 2: Logistics Coordinator Agent (Agente de SLA)

- **Nome do Agente:** Logistics Coordinator Agent (Agente de Logística & SLA)
 - **Objetivo:** Monitorar continuamente a jornada física de cada pedido em trânsito, comparar prazos e emitir alertas preventivos antes que a entrega atinja o limite do SLA.
 - **Problema Resolvido:** 8,1% dos pedidos entregues fora do prazo prometido, constituindo o principal motivo de avaliações 1 estrela e detratores na plataforma.
 - **Usuários Envolvidos:** Equipe de Operações Logísticas da Olist, Transportadoras Parceiras e Clientes Finais.
 - **Ancoragem Analítica nos Dados:** O tempo médio de transporte é de 12,6 dias. Atrasos geram nota média de 2.57 contra 4.29 de pedidos no prazo.
 - **Benefício Esperado:** Redução de chamados no pós-venda via notificação proativa ao cliente e identificação imediata de gargalos por rota/transportadora.
-

6.3 Agente 3: Seller Success & Growth Agent (Agente de Engajamento)

- **Nome do Agente:** Seller Success & Growth Agent (Agente de Performance de Sellers)
 - **Objetivo:** Avaliar o desempenho comercial e operacional dos lojistas parceiros, fornecendo mentoria automatizada e planos de recuperação para alavancar o GMV e evitar churn.
 - **Problema Resolvido:** Baixa retenção de clientes (96,88% dos clientes compram apenas 1 vez na Olist) e concentração extrema de sellers no Estado de SP (59,7%), onerando o frete para o restante do Brasil.
 - **Usuários Envolvidos:** Vendedores Parceiros (Sellers) e Gerentes de Contas / Seller Success da Olist.
 - **Ancoragem Analítica nos Dados:** A análise RFM revelou que o segmento “Hibernando” detém 33,7% da receita, mas tem recência média de 445 dias. Capacitar os sellers para re-engajar essa base é vital.
 - **Benefício Esperado:** Descentralização geográfica do catálogo de produtos, aumento da taxa de recompra e redução das taxas de cancelamento por parte dos lojistas.
-

Tech Challenge – Fase 1

Alessandro Dos Santos - RM376092

André Palermo - RM374038

Michel Lages Balbuena - RM375667

Spencer Bento - RM377023

Willian Souza - RM375240

7. Arquitetura Conceitual Inicial (Entregável 3 — PDF Tech Challenge)

A arquitetura conceitual abaixo descreve o ecossistema de ingestão, a orquestração dos 3 agentes de IA, suas conexões com as fontes de dados unificadas e os pontos de saída para os usuários finais.

7.1 Desenho do Fluxo de Informação (Diagrama Mermaid)




Diagrama 2

Tech Challenge – Fase 1

Alessandro Dos Santos - RM376092

André Palermo - RM374038

Michel Lages Balbuena - RM375667

Spencer Bento - RM377023

Willian Souza - RM375240

7.2 Componentes da Arquitetura:

- **Fontes de Dados Utilizadas:** A base analítica unificada `olist_unified.csv` (granularidade por pedido), a base de reviews desduplicada e os clusters calculados em `olist_rfm.csv`.
 - **Agentes Propostos:** Review Intelligence Agent, Logistics Coordinator Agent e Seller Success & Growth Agent.
 - **Usuários Envolvidos:** Clientes finais do e-commerce, Lojistas (Sellers) cadastrados na Olist e Equipes de Operações/CX internas.
 - **Entradas e Saídas:** Entradas incluem dados transacionais, notas e textos de avaliações; saídas envolvem mensagens empáticas no CRM, notificações de contingência e recomendações estratégicas em formato JSON.
 - **Interações entre Agentes:** O Agente Logístico reporta atrasos iminentes ao Agente de CX para contextualizar o atendimento. O Agente de CX notifica o Agente de Seller Success quando um lojista acumula reclamações de defeito de produto.
-

Tech Challenge – Fase 1

Alessandro Dos Santos - RM376092

André Palermo - RM374038

Michel Lages Balbuena - RM375667

Spencer Bento - RM377023

Willian Souza - RM375240

8. Estruturação de Prompts para Agentes de IA (Entregável 4 — PDF Tech Challenge)

Em conformidade com a especificação do PDF oficial, apresentamos 1 prompt estruturado para cada um dos 3 agentes, contendo o objetivo do prompt, o contexto fornecido, a instrução principal e o resultado esperado.

Tech Challenge – Fase 1

Alessandro Dos Santos - RM376092
André Palermo - RM374038
Michel Lages Balbuena - RM375667
Spencer Bento - RM377023
Willian Souza - RM375240

8.1 Prompt do Review Intelligence Agent

- **a) Objetivo do Prompt:** Classificar o sentimento e a causa raiz de avaliações de clientes (nota 1 a 5), gerando um rascunho de resposta empática em português e alertas de qualidade.
- **b) Contexto fornecido ao agente:**
 - Dados do Pedido: `order_id`, categoria do produto, dias de atraso logístico (`days_late`).
 - Dados do Review: Nota (`review_score`) e texto digitado pelo cliente (`review_comment`).
- **c) Instrução Principal (Prompt):**

Você é o Review Intelligence Agent da Olist, especialista sênior em Customer Experience (CX) no e-commerce brasileiro.

Sua tarefa é analisar o comentário de avaliação abaixo e extrair informações críticas estruturadas.

DADOS DO PEDIDO:

- ID do Pedido: `{order_id}`
- Categoria do Produto: `{product_category}`
- Dias de Atraso Logístico: `{days_late}` (se ≤ 0 , foi entregue no prazo)
- Nota da Avaliação: `{review_score}`
- Texto do Comentário: `"{review_comment}"`

INSTRUÇÕES:

1. Classifique a CAUSA RAIZ principal em: "Atraso na Entrega", "Qualidade do Produto", "Atendimento", "Problema com Estorno" ou "Outro".
2. Defina o SENTIMENTO do texto: "Muito Negativo", "Negativo", "Neutro", "Positivo".
3. Escreva um RASCUNHO DE RESPOSTA profissional e empático em português (PT-BR) pedindo desculpas e explicando os próximos passos de suporte.
4. Escreva um ALERTA INTERNO DE AÇÃO para o lojista caso a causa raiz seja qualidade do produto ou erro de anúncio.

Responda EXCLUSIVAMENTE em formato JSON com as chaves: "causa_raiz", "sentimento", "justificativa", "rascunho_resposta", "alerta_seller".

- **d) Resultado Esperado:** Saída JSON com diagnóstico da causa raiz, sentimento inferido e minutas prontas de comunicação para o CRM e para o seller, reduzindo o tempo de atendimento humano.

Tech Challenge – Fase 1

Alessandro Dos Santos - RM376092
André Palermo - RM374038
Michel Lages Balbuena - RM375667
Spencer Bento - RM377023
Willian Souza - RM375240

8.2 Prompt do Logistics Coordinator Agent

- **a) Objetivo do Prompt:** Avaliar o risco de atraso em tempo real de um pedido em trânsito e recomendar ações de contingência operacional e mensagens preventivas ao cliente.
- **b) Contexto fornecido ao agente:**
 - Dados da Rota: UF de origem do seller e UF de destino do cliente.
 - Prazos: Data de postagem (`delivered_carrier_date`) e Data limite estimada (`estimated_delivery_date`).
 - Desempenho Histórico: Taxa de atraso histórico na rota e nome da transportadora.
- **c) Instrução Principal (Prompt):**

Você é o Logistics Coordinator Agent da Olist. Seu papel é atuar preventivamente para garantir o SLA de entrega.

Analise a situação do pedido abaixo e determine o risco de atraso.

DADOS DO PEDIDO:

- ID do Pedido: `{order_id}`
- UF de Origem (Vendedor): `{seller_state}`
- UF de Destino (Cliente): `{customer_state}`
- Data de Postagem: `{delivered_carrier_date}`
- Data Limite Estimada de Entrega: `{estimated_delivery_date}`
- Histórico de Atrasos nessa Rota (Últimos 30 dias): `{route_delay_rate}`% de atraso histórico
- Transportadora Responsável: `{carrier_name}`

INSTRUÇÕES:

1. Calcule o nível de risco de atraso ("Baixo", "Médio", "Alto").
2. Identifique o gargalo principal da operação logística deste caso (ex: distância, ineficiência da transportadora, atraso no despacho).
3. Gere uma recomendação de ação de contingência para a equipe de operações.
4. Crie uma sugestão de notificação preventiva (e-mail/SMS) para o cliente acalmando-o e informando que o pedido está sendo acompanhado.

Responda EXCLUSIVAMENTE em formato JSON com as chaves: "nivel_risco", "fator_risco_principal", "acao_contingencia", "mensagem_preventiva_cliente".

- **d) Resultado Esperado:** JSON estruturado contendo a categorização do risco, plano de ação corretivo e mensagem preventiva para o cliente final, mitigando potenciais avaliações negativas.

Tech Challenge – Fase 1

Alessandro Dos Santos - RM376092

André Palermo - RM374038

Michel Lages Balbuena - RM375667

Spencer Bento - RM377023

Willian Souza - RM375240

8.3 Prompt do Seller Success & Growth Agent

- **a) Objetivo do Prompt:** Diagnosticar gargalos operacionais e comerciais de lojistas parceiros e estruturar um plano de recuperação em 3 passos com e-mail de engajamento.
- **b) Contexto fornecido ao agente:**
 - Identificação: `seller_id`, categoria principal de atuação.
 - Métricas Comerciais: GMV acumulado nos últimos 3 meses (`gmv_3m`), tendência de vendas (`gmv_trend`) e taxa de cancelamento.
 - Qualidade: Nota média de avaliação do seller (`avg_review_score`).
- **c) Instrução Principal (Prompt):**

Você é o Seller Success & Growth Agent da Olist. Seu objetivo é ajudar parceiros lojistas a venderem mais e com melhor qualidade, prevenindo cancelamentos e churn. Analise os dados do lojista abaixo e desenhe um plano de recuperação focado.

DADOS DO SELLER:

- ID do Seller: `{seller_id}`
- Categoria Principal: `{top_category}`
- GMV dos últimos 3 meses: R\$ `{gmv_3m}` (Tendência: `{gmv_trend}`)
- Taxa de Cancelamento de Pedidos pelo Seller: `{cancellation_rate}%`
- Média de Avaliações (Review Score Médio): `{avg_review_score}` estrelas

INSTRUÇÕES:

1. Diagnostique os 2 maiores problemas operacionais ou de catálogo que estão travando o crescimento desse lojista.
2. Formule um Plano de Recuperação prático em 3 passos específicos (ex: melhoria de embalagem, revisão de estoque, otimização de preços de frete).
3. Escreva um e-mail de engajamento amigável e motivador apresentando o plano.

Responda EXCLUSIVAMENTE em formato JSON com as chaves: "diagnostico", "plano_recuperacao_passos" (lista), "email_engajamento".

- **d) Resultado Esperado:** Diagnóstico em formato JSON acompanhado por um plano tático de 3 passos e minuta de e-mail personalizada para envio automático ao seller.

Tech Challenge – Fase 1

Alessandro Dos Santos - RM376092

André Palermo - RM374038

Michel Lages Balbuena - RM375667

Spencer Bento - RM377023

Willian Souza - RM375240

9. Conclusão e Próximos Passos (Fase 2)

A Fase 1 estabeleceu uma base de dados sólida e estruturada em CSV contendo as variáveis agregadas de negócio, as coordenadas espaciais integradas de geolocalização e as métricas de tempo de entrega calculadas. As análises de correlação e segmentação RFM subsidiaram o desenho dos agentes de IA de suporte à operação da Olist.

Roteiro para a Fase 2:

1. **Instanciação dos Agentes:** Conectar as bases geradas
2. (dados unificados e RFM) às APIs de Large Language Models (LLMs) via LangChain/LangGraph.
3. **Desenho de Pipelines em Tempo Real:** Criar conectores para rodar os prompts estruturados à medida que novos pedidos/reviews entram na base simulada.
4. **Avaliação Qualitativa:** Testar a assertividade das respostas dos agentes de atendimento comparando as notas inferidas automaticamente com as reais notas dos clientes detratores.